

Réduction Des Couches Convolutives Dans Les Réseaux Profonds

Vincent Martineau,^{1*}

¹Département d'informatique et de génie logiciel, Université Laval, Quebec, Canada

*E-mail: vincent.martineau.1@ulaval.ca.

Il y a eu des recherches expliquant comment réduire les couches de convolution dans les réseaux de neurones. Cependant dans les articles proposés les modèles utilisés sont généralement AlexNet et VGG. Lorsque essayé sur des réseaux plus complexes tels que ResNet et DenseNet les solutions proposées ne fonctionnent pas. Le but ici est d'explorer les limites de cette approche et de proposer une solution afin de pouvoir généraliser à des réseaux plus complexes et profonds que ceux dans l'article original de Molchanov. Les expérimentations seront faites sur le transfert de modèle entre ImageNet vers Cifar10 et nous verrons les gains pouvant être faits sur des réseaux profonds.

Introduction

Les réseaux CNN sont parmi nous depuis très longtemps (1). Ces réseaux sont très utilisés dans le traitement de l'image dans une grande variété de domaines. Ils sont très utilisés dans la classification ou la localisation d'objets. Que ce soit avec les systèmes de surveillance, les voitures autonomes ou les appareils intelligents, ce type de réseaux fait maintenant partie de notre quotidien (2).

Ces réseaux ont montré qu'ils pouvaient obtenir des résultats excédant les capacités humaines (3). Dans plusieurs cas, ces modèles sont rendus disponibles au grand public et il est possible de les adapter à des problèmes plus simples pour obtenir de très bons résultats (4).

0.1 Description du problèmes

Afin d'utiliser ces réseaux sûrs de petits appareils des techniques (5) ont été évalué dans le passé. Plus récemment, un article propose de faire la réduction de filtres de convolution (6). Cependant l'article se concentre essentiellement sur les réseaux AlexNet et VGG et ne fonctionne pas sur les réseaux plus complexes présent dans PyTorch (7).

Le but de cet article sera d'évaluer le travail nécessaire pour pouvoir pousser cette logique vers des réseaux plus complexes tels que ResNet, DenseNet et SqueezeNet.

Méthode

La méthode utilisée est une variante de la méthode proposée dans l'article Pruning Convolutional Neural networks for Ressource efficient inference (6). Le but des modifications est d'étendre les capacités de notre modèle à des réseaux beaucoup plus complexes tels que ResNet, DenseNet et Squeeze net.

Voici une liste des étapes à suivre pour obtenir une réduction intéressante:

1. appliquer le fine tuning sur un réseau pré-entraîné.
2. Extraire le graphe d'exécution de notre modèle
3. à partir de notre graphe d'exécution, exclure les couches de convolution que nous ne voulons pas affecter.
4. Réduire les filtres en fonction du critère de réduction
5. Appliquer le fine tuning afin de restabiliser le réseau
6. Recommencer la réduction tant que le réseau ne possède pas la taille voulue.

Dans cette procédure le critère de sélection est très important pour avoir de bons résultats. Pour cette expérimentation, nous avons utilisé les Taylor Expansions qui ont prouvé leur efficacité dans l'article et les activations moyennes.

Afin de pouvoir exécuter sur des modèles plus complexes, nous avons choisi de ne pas explorer d'autres critères de sélection, mais bien de se concentrer sur l'algorithme nécessaire pour supporter des modèles plus complexes.

0.2 Les pratiques à éviter

Dans la solution proposée, il est important de ne pas appliquer de réduction de filtres juste avant une addition de flow tel que vu dans plusieurs modèles complexes. La figure Figure1 représente cette situation. Le problème dans ce cas est qu'il est nécessaire d'appliquer une réduction équivalente sur toutes les branches entrantes. Il est possible qu'il existe un critère de sélection permettant d'inclure ces couches dans le futur.




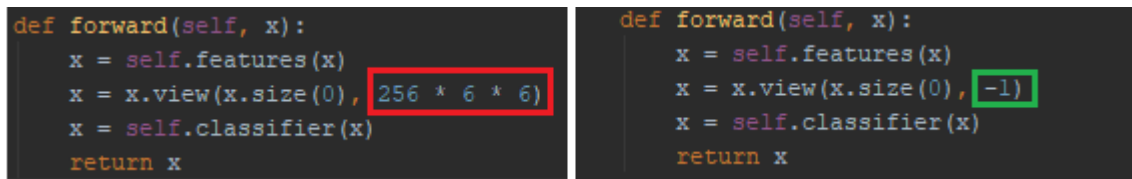
Figure 1: Dans la figure suivante il est impossible de réduire la seconde couche de convolution pour la branche du bas puisqu'il serait aussi nécessaire de modifier la couche précédent ce bloc ResNet pour que la connexion résiduelle aie la bonne taille.

Un autre problème potentiel survient lorsqu'une couche est réutilisée. Dans ce cas il faut que l'input de notre couche soit compatible avec la sortie de la couche que nous traitons. Cependant nous devons affecter les couches précédentes pour que les dimensions concordent aussi.

Il est à noter qu'il est possible qu'il existe un algorithme fiable qui permet de gérer ces cas, mais l'article présent n'explore pas ces options.

0.3 Pratiques à éviter

Lors de la construction du modèle il est très important d'éviter au maximum les valeurs fixes lors de l'inférence. Par exemple, dans le modèle AlexNet, il y a le code de la partie gauche de la figure 2 qui nous empêche de réduire la dernière couche de convolution avant la couche pleinement connectée. En effectuant la modification présentée dans la figure 2, il est maintenant possible de réduire la couche de convolution avant la couche pleinement connectée.



```
def forward(self, x):  
    x = self.features(x)  
    x = x.view(x.size(0), 256 * 6 * 6)  
    x = self.classifier(x)  
    return x
```

```
def forward(self, x):  
    x = self.features(x)  
    x = x.view(x.size(0), -1)  
    x = self.classifier(x)  
    return x
```

Figure 2: On remarque dans la partie de gauche que le code original assume une taille fixe pour la dernière couche de convolution. En plus de limiter le modèle à une certaine taille d'image en entrée on ne peut réduire la dernière couche de convolution. La solution proposée demande la modification dans la section de droite dans l'image qui permet une taille variable de la dernière couche de convolution.

0.4 Propagation de l'effet

Lorsque nous retirons un filtre de convolution d'une couche, il faut prendre plusieurs précautions pour assurer la stabilité du système. Par exemple, il faut ajuster les poids, le nombre de biais dans la couche et ajuster les gradients lorsque ces derniers sont contenus dans la couche elle-même. Ce qui est le cas de PyTorch.

Par la suite, il faut ajuster les couches suivantes en fonction de leur type.

Pour les couches de **convolutions suivantes**. Il est nécessaire d'ajuster le nombre de couches en entrées pour concorder avec la couche de convolution que nous traitons. Il faut aussi ajuster les poids de cette couche.

Pour les couches de **Batchnorm**, il faut ajuster les biais lorsqu'ils sont utilisés et nous effectuons un reset sur les variables utilisées à l'exécution. Dans PyTorch, nous parlons de running means et running vars.

Finalement, nous devons ajuster les couches **pleinement connectées**. Dans le cas de ces couches, nous ajustons les poids et nous appliquons la *weight inference rule* (8) afin de simuler le retrait des poids par *dropout*.

Les autres couches semblent bien supporter la réduction de couches de convolution. Il est à noter que nous avons uniquement essayé les modèles proposés dans PyTorch et que d'autres travail pourrait être nécessaire pour des couches plus complexes.

Résultats

Dans un premier temps, nous évaluons l'effet de la réduction des filtres de convolution sur le modèle AlexNet. La figure 3 montre les effets de la réduction. Le premier résultat que nous pouvons remarquer c'est qu'une succession de réduction trop prononcée réduit considérablement l'effet de pré-entraînement.

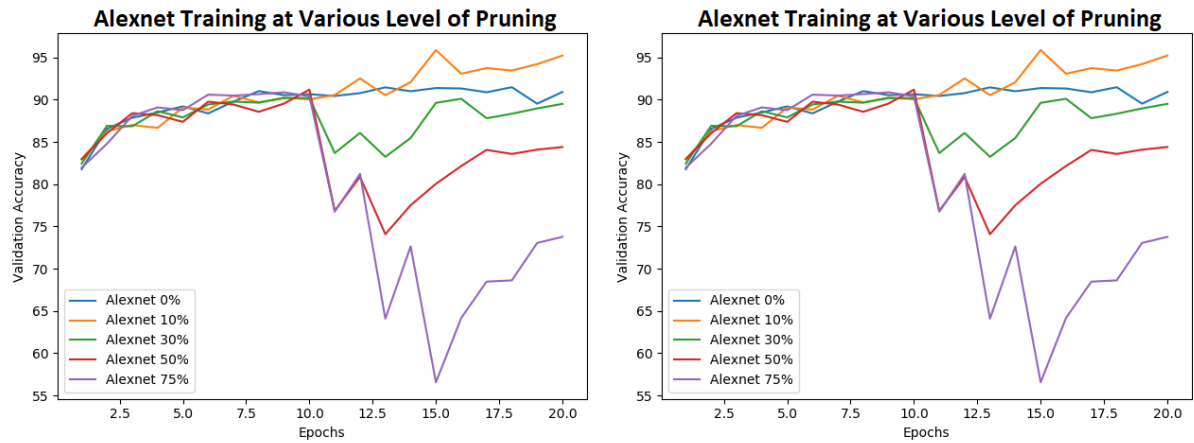


Figure 3: Dans la figure de gauche, on constate une réduction importante des poids à chaque itération. C'est à dire que la réduction des poids est fait en seulement 3 itérations. Sur la figure de droite, on voit une réduction beaucoup plus progressive fait sur 10 itérations.

Par la suite, nous comparons la différence d'efficacité entre les modèles. Cette différence est visible dans la figure 4 qui compare les modèles peu profonds dans la section de gauche et les modèles profonds de Pytorch dans le graphique de droite. Dans tous les cas, on remarque que même avec une réduction de 30% pouvant être coupé il est possible de réduire significativement le réseau et maintenir un niveau de performance.




Figure 4: Dans l'image de gauche on peut observer l'effet de la réduction sur les modèles peu profonds. Dans l'image de droite on voit l'effet de la réduction sur les réseaux profonds de PyTorch.

En examinant l'effet de la réduction sur les paramètres dans la figure[XXX] et le nombre de FLOPs on voit qu'il y a un lien entre ABC et XYZ. Finalement nous allons examiner les effets de la réduction sur le modèle Resnet18 par increment pour avoir une bonne de la perte d'efficacité.

Conclusion

References and Notes

1. Backpropagation Applied to Handwritten Zip Code Recognition:
<http://yann.lecun.com/exdb/publis/pdf/lecun-89e.pdf> .
2. 30 amazing applications of deep learning: <http://www.yaronhadad.com/deep-learning-most-amazing-applications/> .
3. K. He, X. Zhang, S. Ren, and J. Sun. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. In ICCV, 2015.
4. A Survey on Deep Transfer Learning <https://arxiv.org/pdf/1808.01974.pdf> .
5. Bandwidth-efficient deep learning <https://dl.acm.org/citation.cfm?id=3199847> .
6. PRUNING CONVOLUTIONAL NEURAL NETWORKS FOR RESOURCE EFFICIENT INFERENCE : <https://arxiv.org/pdf/1611.06440.pdf> .
7. <https://pytorch.org/docs/stable/torchvision/models.html> .
8. Srivastava et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting..